# Valhalla 与同类产品详细对比（含持续优化能力）

> 版本：v1.0 · 日期：2026-11-13 范围：ValhallaBase / valhalla-server vs Mem0、Zep/Graphiti、Letta、Engram（相邻品类），及全上下文 LM、普通 RAG、LM 微调/LoRA 基线 定位一句话：Valhalla 不是又一个“抽取 → 向量/图 → 注入 prompt”的记忆 API，而是**结构可训练的运行时本体**（Triad 会话 + Fate 门控 + 可烘焙权重），LM 只是可选解码头。

---

## 0. 阅读须知：三档证据，禁止混引

业界最常见的错误，是把不同协议、不同语料、不同骨干的数字直接排成一张“排行榜”。本报告把所有数字分成三档，引用时必须带档位：

| 档位 | 含义 | 可比性 |
|---|---|---|
| **A • 同题实测** | 同一批问题、同一骨干（Qwen2.5-3B 行业标定）下多系统实测 | 可横向对比，但样本量小（n=10–30） |
| **B • Valhalla 内部协议** | Valhalla 自有协议（U1–U4、TPI-v2、fate-longchain 等）下的测量 | 证明“该能力存在且可复现”，**不等于**行业基准胜出 |
| **C • 厂商自报** | 各厂商用自有协议/基准公布的数字 | 口径各异，只能作背景，**禁止**与 A/B 档拼表排名 |

硬边界（源自仓库 SSOT 文档，禁止对外宣称）：

- 禁止宣称“在 LoCoMo / LongMemEval 上击败 Mem0”；
- 禁止宣称“RAGTruth 100/100”为当前值（当前：live 38/40、完整缓存 88/100）；
- 禁止宣称“长链 composite 0.95”为当前值（当前 ≈0.882；0.95 是 v1 历史最小集）；
- “留出集 100%”必须同时注明协议 `fate-longchain-unified-v5`、n=3，且与行业 LoCoMo 分开。

---

## 1. 产品定位与架构对比

| 维度 | ValhallaBase | Mem0 | Zep / Graphiti | Letta（MemGPT） | Engram | 普通 RAG | 全上下文 LM |
|---|---|---|---|---|---|---|---|
| 品类 | 结构运行时本体 | 记忆层 API | 时序知识图谱 | Agent 操作系统/运行时 | 学习型企业记忆层 | 检索管线 | 基线 |
| 核心机制 | Hub/Tile/Stem 三体 + Fate 信号门，语料“孵化”为结构快照 | 抽取事实 → 向量（+可选图）→ 检索注入 | 实体/关系抽取 → 时序 KG（有效期窗口） | 自编辑记忆块（core/archival）+ 工具分页 | 训练出的记忆层，压缩企业知识 | 切块 → 向量检索 → 拼 prompt | 全部历史塞进上下文窗口 |
| 记忆载体 | 结构快照（Triad snapshot）+ 语料索引 | 事实条目（向量库/图） | 图节点/边（带时间有效性） | 文本记忆块 | 模型内/近模型记忆 | 向量索引 | 无（每次全量重发） |

| 维度 | ValhallaBase | Mem0 | Zep / Graphiti | Letta（MemGPT） | Engram | 普通 RAG | 全上下文 LM |
|---|---|---|---|---|---|---|---|
| LM 角色 | 可选解码头，可换骨干；open 类走 native，mcq 走 LM 头 | 负责抽取与作答，和记忆层绑定使用 | 负责作答 | 运行时与模型耦合 | 与训练耦合 | 负责作答 | 本体即作答 |
| 部署形态 | 本地运行时/自托管服务器（本项目 valhalla-server），引擎与权重加密落盘 | 托管 API / 自托管 | 托管 / 自托管（Neo4j 等） | 自托管/云 | 商业 SKU | 自建 | API |
| 多租户/SaaS 成熟度 | 低（研究型运行时） | 高（主打卖点） | 高 | 中 | 高 | 自建 | 高 |

结论：Mem0/Zep/Letta 解决的是“给现有 LLM 应用加一层记忆”；Valhalla 的竞争面不在这一层——它把“会话状态、路由、拒答、持续学习”下沉为结构本身。把两者按同一个 API 维度打分会系统性误判双方。

---

## 2. 硬指标对比（A 档：同题实测）

协议：`competitor-compare` moderate 集（2026-07-13），骨干锁 Qwen2.5-3B 仅作行业标定。Valhalla 该轮为 hybrid full 配置。

| 基准 | 全上下文 LM | 普通 RAG | Valhalla | Mem0（本地语义检索） |
|---|---|---|---|---|
| LoCoMo-15（moderate） | 9/15（60%） | 9/15（60%） | **0/15（0%）** | 5/15（33%） |
| MultiHop-10 | 6/10 | 6/10 | **6/10** | 6/10 |
| LongBench-10 | 2/10 | 2/10 | **1/10** | 2/10 |

行业全量口径补充（不同 n，勿与上表拼行）：`locomo-v1` 全会话（~280+ 行、30 题盲检索）Valhalla 为 **14/30（47%，Tier B）**；厂商自报数字（如 Mem0 的 LongMemEval 宣传值）属 C 档，仓库明确注明“不复现、不引用为对比结论”。

**解读（必须原样保留）**：

1. 在记忆 API 们的主场（LoCoMo 式长对话问答）上，Valhalla 目前是**明确落后**的：同题 0/15 vs RAG 9/15。这不是口径问题，是当前开放问答/证据落地（egress）能力的真实差距。
2. MultiHop 上四家打平，说明差距不在“多跳推理骨架”，而在长会话证据召回与落地的最后一公里。
3. 因此 Valhalla 的可辩护卖点**只能**来自第 3 节的独有协议，不得用 A 档数字做领先宣称。

---

## 3. Valhalla 独有能力指标（B 档：内部协议）

以下为仓库 SSOT（`CANONICAL_METRICS_20260714`，2026-07-14）与可复现 runner 的现行值：

### 3.1 独有证明套件 U1–U4（4/4 通过且可引用）

| 编号 | 能力 | 指标 | 对照 |
|---|---|---|---|
| U1 | 非隔离多模态共享结构补丁 | 共享 **0.9999** | 隔离式 0.968；12/12 任务胜 |
| U2 | Fate 主动触发 + 不匹配拒答 | MAR **1.0** / FIR **0.0** / PPI 0.65 | 同行无代数式 emit/abstain 门 |

| 编号 | 能力 | 指标 | 对照 |
|---|---|---|---|
| U3 | 零权重污染救援 | **+38.7pp**（48.4% → 87.1%） | 见第 5 节 |
| U4 | 骨干正交性 | `VALHALLA_BASE_INDEPENDENT` | 换解码头结构不崩 |

U5（成本@准确率地板）**未过**：fast 口径 prefill 比例 ≈0.29×、on-topic ≈0.55，未达 ≥0.80 地板，只能标“发展中可引用”，禁止单独引用成本数字。

### 3.2 忠实度与长链连续性

| 指标 | 现行值 | 协议/备注 |
|---|---|---|
| RAGTruth | live **38/40**；完整缓存 **88/100** | `ragtruth-v1`，Tier A 强项（忠实落地） |
| 长链主题漂移 theme_drift | **0%** | `fate-longchain-unified-v5`，`fragment_full`，生产 128L |
| 长链保持 retention | **100%** | 同上 |
| 长链留出 QA | 100%（**3/3**） | n=3 小切片，必须注明 |
| 长链交错 QA | 75%（3/4） | 残留：`LOCO_0_6` 六月露营题仍错 |
| 长链 composite | **≈0.882** | 连续性加权；勿引历史 0.95 |
| 长久记忆 append-then-ask | **72/76（94.7%）** | `long-memory-v1` 生产臂：early 3/3、extended 56/60、reload 10/10、depth 3/3 |
| 多模态非隔离 | **107/107** 胜隔离式 | 同核跨语言 18/18、CCU 0.95；融合 MCQ 5 题切片 +20pp |
| 主动门控 | 71/72，PPI 0.890；gates 3/3 | `proactive-fate-v2`，信号时间门 ≥64 tick |
| 结构形成 | 16 tiles / 108 stems / hub 104×4 | `triad-structure-highlight-v1`；自然 NN 拓扑 Stem σ≈9.27 |

### 3.3 本服务器实测（2026-11-13，valhalla-server，仅证明管线打通，非基准）

| 阶段 | 实测 | 备注 |
|---|---|---|
| 分解+适配 | 24 层，5 轮，`fate_converged`；decompose 0.8117，closure 0.6843，aggregate 0.2123 | `valhalla-model-decompose-v1`，Qwen2.5-0.5B 按层深四分 |
| 三模态融合 | 4 样本×4 轮 + 8 轮闭合，aggregate 0.3875 | `valhalla-free-multimodal-fusion-v3`，非隔离单会话 |
| 烘焙 | 强度 0.08，`weight_delta_norm` 0.5987 | 仓库 L3 标准点为 s=0.10、Δw≈298（大规模语料）；本机为 4 样本小样，量级不可比 |
| 发布 | `unified-core-v1`，VALENC1 加密落盘，端点验证 200 | `data/models.json` |

---

## 4. 能力矩阵（定性，源自仓库同行矩阵并补齐）

| 能力 | Valhalla | Mem0 | Zep/Graphiti | Letta | Engram | 普通 RAG |
|---|---|---|---|---|---|---|
| 非隔离多模态（同一结构同时吃文本/音频/图像并共享补丁） | **有（U1）** | 部分（图片/PDF 存为额外记忆，prompt 层晚融合） | 无共享体 | 文本块分层，无三体脉冲 | 不同赌注（知识压缩） | 无（各模态各自索引） |

| 能力 | Valhalla | Mem0 | Zep/Graphiti | Letta | Engram | 普通 RAG |
|---|---|---|---|---|---|---|
| 主动触发 + 不匹配拒答（代数门，而非应用层定时器） | **有（U2）** | 无（查询时被动拉取） | 无（应用层排程） | agent 循环可提示，无 emit/abstain 门 | 不适用 | 无 |
| 零权重会话学习/污染救援 | **有（U3）** | 检索全量仍会被污染 | 图可保留矛盾+有效期，是另一类问题 | 可编辑块，无 TPI 类协议 | 靠训练后的 engram 保持 | 无（索引脏了就脏了） |
| 换骨干解码头、结构不动 | **有（U4）** | 记忆与抽取/作答 LM 绑定使用 | 需服务+LM 作答 | 运行时与模型耦合 | 与训练耦合 | 可换（但结构即索引，无额外状态） |
| 追加成本结构（增量喂入而非全量重发） | 有（U5 地板未过，发展中） | 紧凑事实有帮助，仍重注入检索文本 | 图检索→prompt | 工具分页仍增长上下文 | **核心卖点（1–10% token）** | 全量重发 |
| 时序事实有效期（“何时为真”） | 非主打 | Pro 图可选 | **核心卖点** | 有限 | 训练记忆的时间点 | 无 |
| 托管记忆 API 成熟度（多租户、控制台、SDK） | 低 | **高** | 高 | 中 | 高 | — |

---

## 5. 持续优化能力对比（本报告新增重点）

“持续优化”在各家是**四件不同的事**，必须先对齐定义，否则数字不可比：

| 路线 | 代表 | “优化”发生在哪 | 是否动权重 |
|---|---|---|---|
| 会话内结构学习 | **Valhalla L1** | 会话结构快照、行亲和、Fate 反馈 | 否 |
| 结构监督预训练 | **Valhalla L2** | 语料行亲和、hub 分布收敛 | 否 |
| 结构烘焙 | **Valhalla L3** | 融合结构按强度写入新检查点 | **是（一次性受控写入，非 SGD）** |
| 事实抽取更新 | Mem0 / Zep | 记忆库条目增删改、时序失效 | 否 |
| Agent 自编辑 | Letta | 记忆块改写 | 否 |
| 索引更新 | 普通 RAG | 向量索引增量入库 | 否 |
| 梯度持续学习 | LM 微调/LoRA、Engram 类 | 参数 | 是（SGD） |

### 5.1 Valhalla 三层持续优化实测（B 档，协议见附录）

| 层 | 指标 | 结果 | 证据强度 |
|---|---|---|---|
| L1 推理期学习 | TPI-v2 综合指数 | **0.755** [0.640, 0.811] | A（内部协议最强） |
| L1 | NPPI 新范式指数 | 0.848 [0.711, 0.924] | B |
| L1 | 干净基线（每题新会话+定向喂入） | 87.1%（27/31） | A |
| L1 | 全量灌入污染后 | 48.4%（15/31） | A |
| L1 | 迁移修复 | **87.1%（+38.7pp）** | A（U3 同源） |
| L1 | 语料外新知识零权重摄入 | **6/6** | A−（合成集） |

| 层 | 指标 | 结果 | 证据强度 |
| --- | --- | --- | --- |
| L1 | 30 轮课程式持续摄入 | **96.7%** | B |
| L1 | 数据效率 | 10% 定向语料即达天花板 **100%** | B |
| L1 | 孵化深度扫描 cycles=1/2/4/8 | 全部 87.1%，**无增益** | 重要阴性结论：深度不是瓶颈，杠杆在路由+定向摄入+迁移 |
| L2 监督预训练 | 训练收敛 / 留出 | 3/3 收敛（1 epoch）；留出烟雾 ≥2/3、完整回归 3/3 | A−（17 行小语料、n=3） |
| L3 烘焙 | 权重变化 | s=0.10 时 **Δw≈298**，12 轮闭合 | B：只证明产物可导出；**烘焙后 MCQ 提升未闭环引用**（融合仓公平口径烘焙后 MCQ 15/46，低于旧烘焙 26/46） |
| 长程连续性 | theme_drift / retention | 0% / 100%（128L 生产） | B（小切片） |

### 5.2 与同类路线逐项对比

| 对比项 | Valhalla（L1+L2+L3） | Mem0 | Zep/Graphiti | Letta | 普通 RAG | 微调/LoRA |
| --- | --- | --- | --- | --- | --- | --- |
| 新知识进入方式 | 定向结构摄入 → 快照更新；可选烘焙成权重 | 抽取事实入库 | 抽取实体/关系入图 | agent 改写记忆块 | 切块入库 | 梯度更新 |
| 优化延迟 | 会话内即时（零梯度） | 入库即时 | 入图即时 | 即时 | 入库即时 | 需训练一轮（分钟–小时级） |
| 单次优化成本 | 结构信号更新，无反向传播 | 一次抽取 LM 调用 | 抽取+图写 | 一次 LM 调用 | embedding | 全量/LoRA 反向传播 |
| 抗污染（脏数据灌入后能否自救） | **有协议证据：+38.7pp 修复** | 无同类机制（检索面仍脏，可靠更新/删除 API 人工治理） | 靠时序失效与矛盾保留治理，是“版本管理”非“自救” | 靠 agent 自我编辑，无量化协议 | 无（需重建索引） | 易灾难性遗忘，需回放/正则 |
| 冲突/过时信息处理 | Fate 反馈+亲和衰减（协议内） | UPDATE 操作覆盖 | **最强：双时间有效期、事实失效** | 块覆盖 | 无原生 | 覆盖式遗忘不可控 |
| 遗忘控制 | 快照可迁移/回滚（transfer fresh） | 可删条目 | 可按时间失效 | 可删块 | 删索引 | **最难（灾难性遗忘）** |
| 可迁移性 | **快照跨新会话迁移（已测）** | 导出记忆库迁移 | 图迁移 | 块迁移 | 索引迁移 | 权重即迁移物，但与任务耦合 |
| 多模态持续摄入 | **同一结构共享补丁（U1 0.9999）** | 分开存、prompt 融合 | 以文本/结构化为主 | 文本为主 | 各模态独立索引 | 需多模态训练 |
| 优化能否沉淀为模型资产 | **能（L3 烘焙出新检查点）** | 不能（资产是记忆库） | 不能（资产是图） | 不能（资产是块） | 不能（资产是索引） | **能（本职）** |
| 量化证据（同行可复现） | TPI/NPPI/救援/课程四组 | 厂商基准为主（C 档） | DMR 等厂商/论文口径（C 档） | 产品演示为主 | — | 学界基准成熟 |
| 已知天花板 | 干净集上不敌 trad_lm（87.1% vs 100%）；加深度无增益；L3 效果未闭环 | 天花板=检索+prompt 注入质量 | 天花板=抽取与作答 LM | 上下文仍增长 | 天花板=召回质量 | 天花板高，但成本与遗忘代价大 |

### 5.3 持续优化结论

1. **“越用越好用”在 Valhalla 身上是被测过的，但形态特殊**：它涨的不是权重，而是结构快照。最硬的证据是污染救援（+38.7pp）和 30 轮课程 96.7%；在干净数据上它只打平冷启动 RAG（87.1%），并不超过传统 LM（100%）。
2. **“多跑轮次就会持续变强”是错的**：cycles 1→8 完全无增益。Valhalla 的持续优化杠杆是**路由质量、定向摄入、快照迁移**，不是堆孵化深度——这与 Mem0 们“多存多检索”也不是一回事。
3. **与梯度路线互补而非替代**：唯一能把持续优化沉淀成权重资产的是 L3 烘焙，但烘焙后问答提升目前**未闭环**（融合仓 MCQ 反而下降）。今天若要“持续优化→模型变强”的硬承诺，LoRA/微调仍是唯一成熟路线；Valhalla 的承诺应限定在“会话层持续变好 + 结构可导出”。
4. **与 Mem0/Zep 的真实分工**：持续优化若指“事实库的增删改与时序治理”，Zep 最强、Mem0 最易用；若指“不改权重让同一会话从污染中自愈并迁移到新会话”，只有 Valhalla 有量化协议。同行在这一点上不是“分数低”，是**没有这个机制。**
5. **缺口（未测）**：无周/月级数据流基准、无大规模遗忘曲线、无 MemoryBench 式流式评测；L2 仅 17 行小语料（n=3）；本服务器尚未在本机复跑 TPI/L2 证明链，仅打通了 L3 生产管线（见 3.3，小样本）。

---

## 6. 选型建议（按场景）

| 场景 | 首选 | 理由 |
|---|---|---|
| 给现有产品快速加“记住用户” | Mem0 | API 成熟度碾压，Valhalla 不是这一层 |
| 事实随时间变化、需审计“何时为真”（CRM/合规） | Zep/Graphiti | 时序有效期是其核心设计 |
| 长时运行的自编辑 agent | Letta | agent-as-OS 心智最接近 |
| 通用文档问答、快速上线 | 普通 RAG / 全上下文 | A 档同题下准确率与成本最稳妥（LoCoMo 9/15） |
| 多模态同体、主动提醒+拒答、污染自愈、可烘焙自有模型 | **Valhalla** | U1–U4 是其他家没有的机制；但须接受 LoCoMo 式 QA 的当前差距 |
| 要求模型本体持续变强且可回归验证 | LoRA/微调（+ Valhalla L3 观察） | 梯度路线证据链成熟；L3 待 MCQ 闭环后再承诺 |

---

## 7. 风险与未证明清单

| 事项 | 状态 |
|---|---|
| LoCoMo 式长对话 QA | 同题 0/15，明确落后，先修证据落地（egress）再谈超越 |
| U5 成本@地板 | on-topic 0.55 < 0.80，成本宣称暂缓 |
| L3 烘焙后 QA 提升 | 未闭环，融合仓口径曾下降（15/46 vs 26/46） |
| L2 预训练规模 | 17 行/n=3，需扩到 8 训/5 测再引用 |
| 长链留出 | n=3/n=4 小切片，不得外推为 SOTA |
| 长期持续学习（周/月流+遗忘曲线） | **全行业在该口径都缺同题数据**，Valhalla 亦未测 |
| 本机复现 | TPI/L2 证明链未在本机复跑；服务器仅 L3 管线实测（4 样本） |

---

## 附录 A：数据来源与复现

| 结论 | 来源文档/工件（仓库路径） | 复现入口 |
| --- | --- | --- |
| 现行指标 SSOT | `valhalla-unified-core/docs/CANONICAL_METRICS_20260714.md` | `reports/valhalla_inference/PROOF_SCORECARD.md`（17 项） |
| 三层可训练性 | `valhalla-unified-core/docs/TRAINABILITY_PROOF.md` | `./scripts/run_highlight_test.sh --train-proof` |
| 孵化/持续优化细节 | `valhalla-unified-core/docs/INCUBATION_CAPABILITY.md` | `test_valhalla_base_training_potential.py --protocol v2` |
| 同行能力矩阵 | `Valhalla-main/docs/valhalla/UNIQUE_VS_MEMORY_APIS.md` | `./scripts/run_unique_proofs.sh --fast` |
| 同题对比口径 | `Valhalla-main/docs/valhalla/COMPETITOR_COMPARE.md` | `run_competitor_compare.py --moderate` |
| 本服务器实测 | `valhalla-server/data/models.json` | `POST /v1/pipeline`，产物 `data/builds/unified-core-v1` |

证据工件：`valhalla_base_training_potential_test_v2.json`、`fate_pretrain_holdout.json`、`bake_crossmodal12.json`、`fate_longchain_unified.json`。

## 附录 B：口径速查（防混引）

| 数字 | 口径 | 禁止搭配 |
| --- | --- | --- |
| 47%（14/30） | `locomo-v1` 行业全会话，Tier B | 不得与 17 行 L2 的 6/6 混称“LoCoMo 成绩” |
| 6/6（100%） | `fate-pretrain-holdout-v1`，17 行小语料 | 不得称“LoCoMo SOTA” |
| 87.1% | `valhalla-base-training-potential-v2`，31 题 fair 集 | 不得称“击败 RAG”（同集 trad_lm 100%） |
| 100% 留出 | `fate-longchain-unified-v5`，n=3 | 不得与行业 LoCoMo 并列 |
| Δw≈298 | L3 烘焙 s=0.10、12 轮闭合 | 不得直接等同“问答变强”（MCQ 未闭环） |
| 0.5987 | 本机 4 样本、s=0.08 | 不得与 Δw≈298 比大小（语料规模不同） |

---

*Rogue Intelligence LNC · 本报告数字均可回溯到上列工件；无来源的数字不写入本报告。*